

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
ELEKTROTEHNIČKI FAKULTET

Diplomski studij računarstva

Laboratorijska vježba 6

Neuronske mreže

Raspoznavanje znamenaka korištenjem konvolucijskih neuronskih mreža

Denis Lazor, DRB

Osijek, 2020.

SADRŽAJ

- 1. UVOD1
- 2. KONVOLUCIJSKE NEURONSKE MREŽE2
- 3. PROGRAMSKI KOD3
 - 3.1. Standarna neuronska mreža.....3
 - 3.2. Konvolucijska neuronska mreža4
- 4. REZULTATI6
- 5. Zaključak16

1. UVOD

Zadatak ove vježbe je bio testirati standarnu i konvolucijsku neuronsku mrežu na MNIST podacima koji predstavljaju brojeve od 0 do 9 koje treba razvrstati u istoimene kategorije koristeći različite veličine filtera i različite aktivacijske funkcije.

2. KONVOLUCIJSKE NEURONSKE MREŽE

Duboko učenje je grana strojnog učenja, dok je konvolucijska neuronska mreža konkretna implementacija dubokih neuronskih mreža koja se najčešće primjenjuje za analizu i raspoznavanje slika. Standardne neuronske mreže nisu osobito prigodne u svrhu analize slika zbog zahtjeva da svaki neuron mora biti povezan sa svim elementima iz prethodnog sloja. Stoga ako npr. imamo sliku veličine 25×25 što znaci ukupno 225 piksela u konačnici će rezultirati s 225 težina koje je potrebno podesiti i optimizirati samo za jedan jedini neuron. Stoga, ako je slika skromnih 100×100 piksela to je već 10000 težina po neuronu i ako imamo 100 neurona u jednom sloju ispada 1000000 težina koje se moraju podesiti. Konvolucijske neuronske mreže imaju takvu arhitekturu koja omogućava da se raspoznaju uzorci različitih dimenzija uz puno manje parametara koje je potrebno podesiti i optimizirati. Smisao konvolucijske neuronske mreže jest da se kroz slojeve neuronske mreže uče raspoznavati inkrementalno kompleksniji uzorci. Ako se uči npr. raspoznavanje ljudskih lica, na prvoj razini se raspoznaju linije, rubovi i različiti točkasti uzorci, na drugoj su to npr. dijelovi lica kao što je to nos, uho, usta, oko i sl., dok na idućoj razini su to veći dijelovi lica itd. Drugim riječima, svaki sloj konvolucijske neuronske mreže uči različitu razinu apstrakcije ulaznih podataka. Iako konvolucijska neuronska mreža može imati mnogo različitih dijelova, tipični dijelovi uključuje sljedeće slojeve:

- Konvolucijski sloj (engl. Convolution layer)
- Sloj sažimanja (engl. Pooling Layer)
- Potpuno povezani sloj (engl. Fully-Connected (dense) Layer)

Unutarnja struktura tipične konvolucijske neuronske mreže sastoji se od nekoliko naizmjenično poslaganih višedimenzionalnih konvolucijskih slojeva i slojeva sažimanja. Na kraju se nalazi potpuno povezan sloj, koji je jednodimenzionalan, kao i izlazni sloj. Fundamentalna razlika između konvolucijskog sloja i potpuno povezanog sloja (istovrstan standardnoj neuronskoj mreži), jest to što potpuno povezan sloj uči uzorke globalno dok konvolucijski sloj uči lokalne uzorke unutar malih dvodimenzionalnih prozora nazvanih jezgra (engl. kernel). Tako naučne lokalne uzorke konvolucijski sloj nauči raspoznavati na bilo kojem mjestu na slici, dok bi na primjer standardne neuronske mreže naučile raspoznavati samo na točno određenom mjestu. Stoga ako bi neka značajka promijenila svoj položaj, standardna neuronska mreža bi morala ponovo biti naučena. Još jedna bitna značajka konvolucijskih slojeva je ta da može naučiti odnosno zadržati prostorne odnose između uzoraka. Ako se na primjer u prvom konvolucijskom sloju uče osnovni uzorci kao što su rubovi, linije, prijelazi i sl. tada se u drugom sloju mogu naučiti kompleksne kompozicije tih osnovnih uzoraka iz prethodnog sloja. Time se iz sloja u sloj povećava kompleksnost apstraktnih vizualnih koncepata. Konvolucijski slojevi i slojevi sažimanja se baziraju na 3D tenzorima nazvanima mape značajki (engl. feature map), koje imaju širinu, visinu i dubinu. Ulazni slojevi mogu isto imati te tri dimenzije, ako se radi o crno-bijeloj slici tada pored širine i visine ima samo dubinu od 1, dok slike u boji imaju dubinu 3 (crvena, zelena i plava komponenta slike). Konvolucijski sloj radi na principu konvolucije gdje maleni prozor „klizi“ po slici, umnaža elemente (piksele) slike i potom ih sumira, te uz dodatak bias-a „pridružuje“ neuronu na odgovarajućem mjestu konvolucijskog sloja. Vizualno, obradu krećemo s prozorom u gornjem lijevom kutu slike koji daje potrebne informacije prvom (opet, gornji lijevi kut) neuronu konvolucijskog sloja. Nakon toga pomičemo prozor za jedno mjesto u desno i povezujemo vrijednosti s drugim neuronom u konvolucijskom sloju i tako obilazimo cijelu sliku.

3. PROGRAMSKI KOD

3.1. Standardna neuronska mreža

Modificiran je kod od vježbe LV5 tako da prima MNIST podatke i klasificira znamenke od 0 do 9. Podatci su razvučeni u vektor i skalirani na vrijednosti između 0 i 1.

```
#-- Added by Denis Lazor
(X_train, y_train), (X_test, y_test) = mnist.load_data()
image_vector_size = 28*28

X_train = X_train.reshape(X_train.shape[0], image_vector_size)
X_test = X_test.reshape(X_test.shape[0], image_vector_size)
X_train = X_train.astype('float32') / 255
X_test = X_test.astype('float32') / 255
```

Slika 3.1.1. Priprema podataka

Dio koda je izmjenjen tako da su kategorije brojevi od 0 do 9.

```
class_names = np.array([0,1,2,3,4,5,6,7,8,9]) # Modified by Denis Lazor
```

Slika 3.1.2.. Dodavanje kategorija klasifikacije

3.2. Konvolucijska neuronska mreža

Kod prikazan na slici 3.2.1. predstavlja 2 polja potrebna za automatsko prolaženje kroz kombinacije te učitavanje i pripremu MNIST podataka za konvolucijsku neuronsku mrežu.

```
from keras import layers
from keras import models

from keras.datasets import mnist
from keras.utils import to_categorical

WindowSize = [(3, 3), (5, 5), (7, 7)]
Activation = ["relu", "tanh", "sigmoid"]

### Data preparing ###
(X_train, y_train), (X_test, y_test) = mnist.load_data()

X_train = X_train.reshape(60000, 28, 28, 1)
X_train = X_train.astype('float32') / 255
X_test = X_test.reshape(10000, 28, 28, 1)
X_test = X_test.astype('float32') / 255
y_train = to_categorical(y_train, num_classes=10)
y_test = to_categorical(y_test, num_classes=10)
```

Slika 3.2.1. Priprema podataka

Kod za automatsko testiranje svih kombinacije se nalazi na slici 3.2.2.

```
for win_size in WindowSize:
    for activ_fn in Activation:

        ### Model 1 ###
        model_1 = models.Sequential()
        model_1.add(layers.Conv2D(64, win_size, activation=activ_fn, input_shape=(28, 28, 1)))
        model_1.add(layers.Conv2D(32, win_size, activation=activ_fn))
        model_1.add(layers.Flatten())
        model_1.add(layers.Dense(10, activation='softmax'))

        model_1.compile(loss='categorical_crossentropy', optimizer='sgd', metrics=['accuracy'])

        model_1.summary()

        ### Model 2###
        model_2 = models.Sequential()
        model_2.add(layers.Conv2D(64, win_size, activation=activ_fn, input_shape=(28, 28, 1)))
        model_2.add(layers.MaxPooling2D((2, 2)))
        model_2.add(layers.Conv2D(32, win_size, activation=activ_fn))
        model_2.add(layers.MaxPooling2D((2, 2)))
        model_2.add(layers.Flatten())
        model_2.add(layers.Dense(10, activation='softmax'))

        model_2.compile(loss='categorical_crossentropy', optimizer='sgd', metrics=['accuracy'])

        model_2.summary()

        ### Training ###

        model_1.fit(X_train, y_train, validation_data=(X_test, y_test), epochs=5, verbose=2)
        model_2.fit(X_train, y_train, validation_data=(X_test, y_test), epochs=5, verbose=2)
        print(" Window size:" + str(win_size) + ", Activation: " + activ_fn + "\n\n" + 30 * "*" + "\n\n")
```

Slika 3.2.2. For petlja za kombinacije

4. REZULTATI

Eksperimenti su provedeni na način da su se testirale različit kombinacije aktivacijskih funkcija i veličine filtra dok je kod standardne mreže testirana samo jedna kombinacija.

Tablica 1 3x3 Relu

Model	1	2
Aktivacijska funkcija	Relu	Relu
Veličina filtra	3x3	3x3
Broj parametara	203 434	27 114
Preciznost [%]	97.61 %	96.69 %
Preciznost validacije [%]	97.97 %	96.93 %
Vrijeme / epoha[s]	47	29

```
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 51s - loss: 0.4310 - accuracy: 0.8754 - val_loss: 0.2928 - val_accuracy: 0.9164
Epoch 2/5
  - 49s - loss: 0.2565 - accuracy: 0.9262 - val_loss: 0.1811 - val_accuracy: 0.9507
Epoch 3/5
  - 47s - loss: 0.1525 - accuracy: 0.9568 - val_loss: 0.1139 - val_accuracy: 0.9668
Epoch 4/5
  - 47s - loss: 0.1041 - accuracy: 0.9705 - val_loss: 0.0792 - val_accuracy: 0.9775
Epoch 5/5
  - 47s - loss: 0.0826 - accuracy: 0.9761 - val_loss: 0.0683 - val_accuracy: 0.9797
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 30s - loss: 0.6355 - accuracy: 0.8044 - val_loss: 0.3064 - val_accuracy: 0.9063
Epoch 2/5
  - 29s - loss: 0.2364 - accuracy: 0.9297 - val_loss: 0.1729 - val_accuracy: 0.9501
Epoch 3/5
  - 29s - loss: 0.1651 - accuracy: 0.9515 - val_loss: 0.1330 - val_accuracy: 0.9624
Epoch 4/5
  - 29s - loss: 0.1305 - accuracy: 0.9617 - val_loss: 0.1147 - val_accuracy: 0.9655
Epoch 5/5
  - 29s - loss: 0.1107 - accuracy: 0.9669 - val_loss: 0.0982 - val_accuracy: 0.9693
Window size:(3, 3), Activation: relu
```

Slika 4.1. 3x3 Relu

Tablica 2 3x3 Tanh

Model	1	2
Aktivacijska funkcija	Tanh	Tanh
Veličina filtra	3x3	3x3
Broj parametara	203 434	27 114
Preciznost [%]	96.64 %	91.68 %
Preciznost validacije [%]	97.18 %	17.47 %
Vrijeme / epoha[s]	54	33

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
- 54s - loss: 0.3896 - accuracy: 0.8893 - val_loss: 0.2738 - val_accuracy: 0.9219
Epoch 2/5
- 54s - loss: 0.2630 - accuracy: 0.9245 - val_loss: 0.2316 - val_accuracy: 0.9334
Epoch 3/5
- 54s - loss: 0.2172 - accuracy: 0.9370 - val_loss: 0.1981 - val_accuracy: 0.9460
Epoch 4/5
- 54s - loss: 0.1644 - accuracy: 0.9523 - val_loss: 0.1417 - val_accuracy: 0.9600
Epoch 5/5
- 54s - loss: 0.1191 - accuracy: 0.9664 - val_loss: 0.0989 - val_accuracy: 0.9718
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
- 33s - loss: 1.4179 - accuracy: 0.6834 - val_loss: 4.3369 - val_accuracy: 0.1012
Epoch 2/5
- 33s - loss: 0.5132 - accuracy: 0.8722 - val_loss: 3.4960 - val_accuracy: 0.1451
Epoch 3/5
- 33s - loss: 0.3739 - accuracy: 0.8974 - val_loss: 2.9192 - val_accuracy: 0.2086
Epoch 4/5
- 33s - loss: 0.3221 - accuracy: 0.9086 - val_loss: 3.2455 - val_accuracy: 0.2148
Epoch 5/5
- 33s - loss: 0.2920 - accuracy: 0.9160 - val_loss: 3.7166 - val_accuracy: 0.1747
Window size:(3, 3), Activation: tanh

```

Slika 4.2. 3x3 Tanh

Tablica 3 3x3 Sigmoid

Model	1	2
Aktivacijska funkcija	Sigmoid	Sigmoid
Veličina filtra	3x3	3x3
Broj parametara	203 434	27 114
Preciznost [%]	91.89 %	29.18 %
Preciznost validacije [%]	92.91 %	10.09 %
Vrijeme / epoha[s]	54	33

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 52s - loss: 2.3189 - accuracy: 0.1274 - val_loss: 2.0729 - val_accuracy: 0.3213
Epoch 2/5
  - 52s - loss: 0.6179 - accuracy: 0.8302 - val_loss: 0.3475 - val_accuracy: 0.8981
Epoch 3/5
  - 55s - loss: 0.3415 - accuracy: 0.8986 - val_loss: 0.2948 - val_accuracy: 0.9142
Epoch 4/5
  - 54s - loss: 0.3052 - accuracy: 0.9110 - val_loss: 0.2811 - val_accuracy: 0.9194
Epoch 5/5
  - 54s - loss: 0.2821 - accuracy: 0.9189 - val_loss: 0.2572 - val_accuracy: 0.9291
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 33s - loss: 2.3148 - accuracy: 0.1055 - val_loss: 2.3190 - val_accuracy: 0.0958
Epoch 2/5
  - 34s - loss: 2.3006 - accuracy: 0.1159 - val_loss: 2.3157 - val_accuracy: 0.1010
Epoch 3/5
  - 33s - loss: 2.2905 - accuracy: 0.1293 - val_loss: 2.3198 - val_accuracy: 0.1010
Epoch 4/5
  - 34s - loss: 2.2605 - accuracy: 0.1766 - val_loss: 2.3511 - val_accuracy: 0.1009
Epoch 5/5
  - 33s - loss: 2.1604 - accuracy: 0.2918 - val_loss: 2.6441 - val_accuracy: 0.1009
Window size:(3, 3), Activation: sigmoid

```

Slika 4.3. 3x3 Sigmoid

Tablica 4 5x5 Relu

Model	1	2
Aktivacijska funkcija	Relu	Relu
Veličina filtra	5x5	5x5
Broj parametara	180 906	58 026
Preciznost [%]	98.25 %	97.84 %
Preciznost validacije [%]	97.75 %	97.79 %
Vrijeme / epoha[s]	62	34

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 63s - loss: 0.3499 - accuracy: 0.8986 - val_loss: 0.1368 - val_accuracy: 0.9591
Epoch 2/5
  - 62s - loss: 0.1149 - accuracy: 0.9671 - val_loss: 0.0783 - val_accuracy: 0.9745
Epoch 3/5
  - 63s - loss: 0.0839 - accuracy: 0.9749 - val_loss: 0.0730 - val_accuracy: 0.9762
Epoch 4/5
  - 63s - loss: 0.0685 - accuracy: 0.9797 - val_loss: 0.0592 - val_accuracy: 0.9811
Epoch 5/5
  - 62s - loss: 0.0597 - accuracy: 0.9825 - val_loss: 0.0654 - val_accuracy: 0.9775
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 34s - loss: 0.5369 - accuracy: 0.8388 - val_loss: 0.1982 - val_accuracy: 0.9429
Epoch 2/5
  - 33s - loss: 0.1806 - accuracy: 0.9466 - val_loss: 0.1399 - val_accuracy: 0.9574
Epoch 3/5
  - 33s - loss: 0.1312 - accuracy: 0.9612 - val_loss: 0.1096 - val_accuracy: 0.9652
Epoch 4/5
  - 34s - loss: 0.1102 - accuracy: 0.9668 - val_loss: 0.0877 - val_accuracy: 0.9725
Epoch 5/5
  - 34s - loss: 0.0979 - accuracy: 0.9704 - val_loss: 0.0744 - val_accuracy: 0.9779
Window size:(5, 5), Activation: relu

```

Slika 4.4. 5x5 Relu

Tablica 5 5x5 Tanh

Model	1	2
Aktivacijska funkcija	Tanh	Tanh
Veličina filtra	5x5	5x5
Broj parametara	180 906	58 026
Preciznost [%]	98.15 %	92.99 %
Preciznost validacije [%]	98.16 %	10.57 %
Vrijeme / epoha[s]	67	38

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 69s - loss: 0.3566 - accuracy: 0.8993 - val_loss: 0.1943 - val_accuracy: 0.9407
Epoch 2/5
  - 68s - loss: 0.1538 - accuracy: 0.9554 - val_loss: 0.1083 - val_accuracy: 0.9673
Epoch 3/5
  - 66s - loss: 0.0953 - accuracy: 0.9718 - val_loss: 0.0702 - val_accuracy: 0.9787
Epoch 4/5
  - 67s - loss: 0.0740 - accuracy: 0.9777 - val_loss: 0.0640 - val_accuracy: 0.9800
Epoch 5/5
  - 67s - loss: 0.0620 - accuracy: 0.9815 - val_loss: 0.0571 - val_accuracy: 0.9816
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 38s - loss: 1.0092 - accuracy: 0.7277 - val_loss: 5.1370 - val_accuracy: 0.1051
Epoch 2/5
  - 38s - loss: 0.3954 - accuracy: 0.8870 - val_loss: 7.1809 - val_accuracy: 0.1289
Epoch 3/5
  - 37s - loss: 0.3219 - accuracy: 0.9102 - val_loss: 8.4581 - val_accuracy: 0.1133
Epoch 4/5
  - 38s - loss: 0.2858 - accuracy: 0.9216 - val_loss: 10.2234 - val_accuracy: 0.1083
Epoch 5/5
  - 38s - loss: 0.2522 - accuracy: 0.9299 - val_loss: 11.1044 - val_accuracy: 0.1057
Window size:(5, 5), Activation: tanh

```

Slika 4.5. 5x5 Tanh

Tablica 6 5x5 Sigmoid

Model	1	2
Aktivacijska funkcija	Sigmoid	Sigmoid
Veličina filtra	5x5	5x5
Broj parametara	180 906	58 026
Preciznost [%]	92.23 %	48.18 %
Preciznost validacije [%]	93.04 %	12.03 %
Vrijeme / epoha[s]	68	37

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 67s - loss: 2.1243 - accuracy: 0.2244 - val_loss: 0.7058 - val_accuracy: 0.8162
Epoch 2/5
  - 68s - loss: 0.4621 - accuracy: 0.8644 - val_loss: 0.3453 - val_accuracy: 0.8967
Epoch 3/5
  - 68s - loss: 0.3424 - accuracy: 0.8989 - val_loss: 0.2999 - val_accuracy: 0.9133
Epoch 4/5
  - 69s - loss: 0.2986 - accuracy: 0.9123 - val_loss: 0.2704 - val_accuracy: 0.9233
Epoch 5/5
  - 68s - loss: 0.2706 - accuracy: 0.9223 - val_loss: 0.2471 - val_accuracy: 0.9304
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 39s - loss: 2.3090 - accuracy: 0.1041 - val_loss: 2.3381 - val_accuracy: 0.1032
Epoch 2/5
  - 38s - loss: 2.3022 - accuracy: 0.1116 - val_loss: 2.3374 - val_accuracy: 0.1028
Epoch 3/5
  - 38s - loss: 2.2835 - accuracy: 0.1379 - val_loss: 2.3097 - val_accuracy: 0.1028
Epoch 4/5
  - 38s - loss: 2.1733 - accuracy: 0.2808 - val_loss: 2.3037 - val_accuracy: 0.10113
Epoch 5/5
  - 37s - loss: 1.8780 - accuracy: 0.4818 - val_loss: 2.3144 - val_accuracy: 0.12037
Window size:(5, 5), Activation: sigmoid

```

Slika 4.6. 5x5 Sigmoid

Tablica 7 7x7 Relu

Model	1	2
Aktivacijska funkcija	Relu	Relu
Veličina filtra	7x7	7x7
Broj parametara	185 514	104 874
Preciznost [%]	98.34 %	96.24 %
Preciznost validacije [%]	98.35 %	95.01 %
Vrijeme / epoha[s]	76	35

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
- 76s - loss: 0.3260 - accuracy: 0.9036 - val_loss: 0.1172 - val_accuracy: 0.9654
Epoch 2/5
- 76s - loss: 0.1021 - accuracy: 0.9703 - val_loss: 0.0809 - val_accuracy: 0.9747
Epoch 3/5
- 76s - loss: 0.0763 - accuracy: 0.9776 - val_loss: 0.0579 - val_accuracy: 0.9811
Epoch 4/5
- 76s - loss: 0.0622 - accuracy: 0.9820 - val_loss: 0.0527 - val_accuracy: 0.9831
Epoch 5/5
- 76s - loss: 0.0537 - accuracy: 0.9834 - val_loss: 0.0534 - val_accuracy: 0.9835
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
- 35s - loss: 0.5956 - accuracy: 0.8204 - val_loss: 0.2809 - val_accuracy: 0.9146
Epoch 2/5
- 35s - loss: 0.2361 - accuracy: 0.9272 - val_loss: 0.2146 - val_accuracy: 0.9319
Epoch 3/5
- 35s - loss: 0.1738 - accuracy: 0.9474 - val_loss: 0.1400 - val_accuracy: 0.9564
Epoch 4/5
- 35s - loss: 0.1421 - accuracy: 0.9572 - val_loss: 0.1187 - val_accuracy: 0.9648
Epoch 5/5
- 35s - loss: 0.1262 - accuracy: 0.9624 - val_loss: 0.1581 - val_accuracy: 0.9501
Window size:(7, 7), Activation: relu

```

Slika 4.7. 7x7 Relu

Tablica 8 7x7 Tanh

Model	1	2
Aktivacijska funkcija	Tanh	Tanh
Veličina filtra	7x7	7x7
Broj parametara	185 514	104 874
Preciznost [%]	98.21 %	90.76 %
Preciznost validacije [%]	98.17 %	9.78 %
Vrijeme / epoha[s]	78	40

```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 79s - loss: 0.3323 - accuracy: 0.9053 - val_loss: 0.1620 - val_accuracy: 0.9508
Epoch 2/5
  - 78s - loss: 0.1294 - accuracy: 0.9620 - val_loss: 0.0898 - val_accuracy: 0.9716
Epoch 3/5
  - 78s - loss: 0.0883 - accuracy: 0.9728 - val_loss: 0.0650 - val_accuracy: 0.9792
Epoch 4/5
  - 78s - loss: 0.0694 - accuracy: 0.9790 - val_loss: 0.0565 - val_accuracy: 0.9821
Epoch 5/5
  - 78s - loss: 0.0588 - accuracy: 0.9821 - val_loss: 0.0567 - val_accuracy: 0.9817
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 39s - loss: 1.1274 - accuracy: 0.6748 - val_loss: 5.6004 - val_accuracy: 0.1332
Epoch 2/5
  - 39s - loss: 0.5305 - accuracy: 0.8676 - val_loss: 5.8321 - val_accuracy: 0.1732
Epoch 3/5
  - 39s - loss: 0.4430 - accuracy: 0.8889 - val_loss: 7.9909 - val_accuracy: 0.1021
Epoch 4/5
  - 39s - loss: 0.3861 - accuracy: 0.9032 - val_loss: 10.6905 - val_accuracy: 0.0974
Epoch 5/5
  - 40s - loss: 0.3708 - accuracy: 0.9076 - val_loss: 11.1699 - val_accuracy: 0.0977
Window size:(7, 7), Activation: tanh

```

Slika 4.8. 7x7 Tanh

Tablica 9 7x7 Sigmoid

Model	1	2
Aktivacijska funkcija	Sigmoid	Sigmoid
Veličina filtra	7x7	7x7
Broj parametara	185 514	104 874
Preciznost [%]	93.78 %	64.64 %
Preciznost validacije [%]	94.65 %	13.67 %
Vrijeme / epoha[s]	79	39

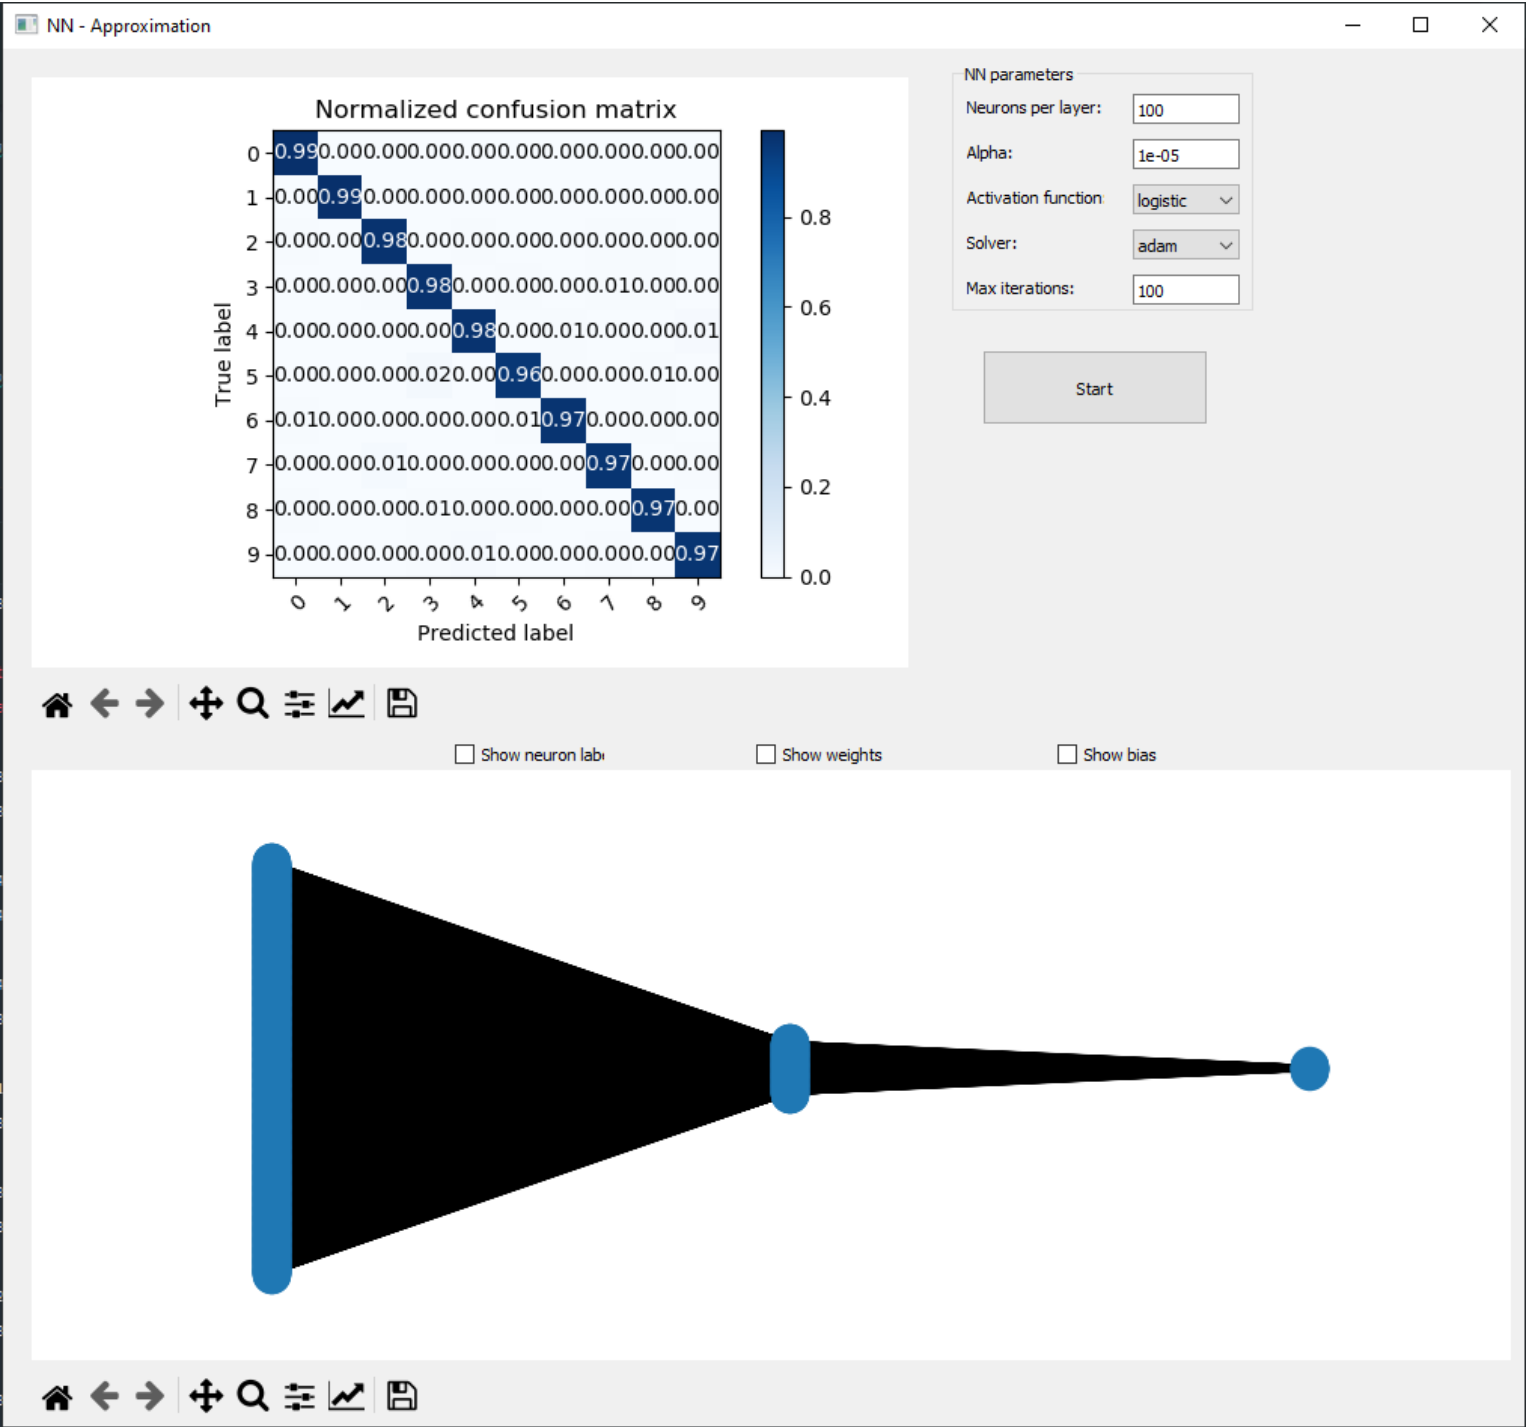
```

Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 79s - loss: 1.8413 - accuracy: 0.3378 - val_loss: 0.5084 - val_accuracy: 0.8549
Epoch 2/5
  - 79s - loss: 0.4148 - accuracy: 0.8767 - val_loss: 0.3274 - val_accuracy: 0.9074
Epoch 3/5
  - 79s - loss: 0.3238 - accuracy: 0.9041 - val_loss: 0.2771 - val_accuracy: 0.9213
Epoch 4/5
  - 79s - loss: 0.2697 - accuracy: 0.9213 - val_loss: 0.2274 - val_accuracy: 0.9337
Epoch 5/5
  - 79s - loss: 0.2250 - accuracy: 0.9348 - val_loss: 0.1889 - val_accuracy: 0.9465
Train on 60000 samples, validate on 10000 samples
Epoch 1/5
  - 39s - loss: 2.3097 - accuracy: 0.1044 - val_loss: 2.3723 - val_accuracy: 0.0982
Epoch 2/5
  - 39s - loss: 2.3005 - accuracy: 0.1166 - val_loss: 2.3201 - val_accuracy: 0.1135
Epoch 3/5
  - 39s - loss: 2.2584 - accuracy: 0.1903 - val_loss: 2.2915 - val_accuracy: 0.1537
Epoch 4/5
  - 39s - loss: 1.9481 - accuracy: 0.4685 - val_loss: 2.2628 - val_accuracy: 0.2191
Epoch 5/5
  - 39s - loss: 1.3668 - accuracy: 0.6464 - val_loss: 3.9420 - val_accuracy: 0.1367
Window size:(7, 7), Activation: sigmoid

```

Slika 4.9. 7x7 Sigmoid

Standarna neuronska mreža:



Slika 4.10. Standarna neuronska mreža

5. Zaključak

Iz rezultata se dobro vidi utjecaj pojedinih aktivacijskih funkcija. Tanh daje dobru preciznost na trening podacima, alijako lošu na validacijskim što je znak da se događa pojava zvana *overfitting*.. Mreža se previše prilagođava trening podacima. Sigmoid ima nešto manju razliku između trening i validacijskih podataka, ali ima još lošiju preciznost dok Relu radi odlično i na trening i na validacijskim podacima stoga nije čudo da je jedna od najkorištenijih aktivacijskih funkcija u neuronskim mrežama. Što se tiče veličine filtera, veći filteri daju malo na preciznosti, ali povećavaju vrijeme izvođenja iako to ne bi trebao biti slučaj. Uzrok tome je vjerovatno to što se mreža učila na CPU-u, a ne na GPU-u ma je bilo problema sa memorijom kod većih filtera. Drugi model koji sadrži slojeve sažimanja ima puno manje parametara za podešavati i puno manje je vrijeme izvođenja, a ne gubi puno na preciznosti pa je to pitanje kompromisa brzine i preciznosti. Također veći filter uzrokuje veći broj podesivih parametara..

Standarna neuronska mreža ima slične rezultate što se tiče preciznosti, ali ima puno više podesivih parametara i njeno učenje s time duže traje te zahtjeva više resursa.